

Normal Equation.

La función de costo se escribe de la siguiente manera:

$$J = \frac{1}{2m} \left(\begin{bmatrix} \theta_0 & \theta_1 & \cdots & \theta_n \end{bmatrix} \begin{bmatrix} 1 & 1 & \cdots & 1 \\ x_1^{(1)} & x_1^{(2)} & \cdots & x_1^{(m)} \\ \vdots & \vdots & \cdots & \vdots \\ x_n^{(1)} & x_n^{(2)} & \cdots & x_n^{(m)} \end{bmatrix} - \begin{bmatrix} y^{(1)} & \cdots & y^{(m)} \end{bmatrix} \right) \\ \cdot \left(\begin{bmatrix} 1 & x_1^{(1)} & \cdots & x_n^{(1)} \\ 1 & x_1^{(2)} & \cdots & x_n^{(2)} \\ \vdots & \vdots & \cdots & \vdots \\ 1 & x_1^{(m)} & \cdots & x_n^{(m)} \end{bmatrix} \begin{bmatrix} \theta_0 \\ \theta_1 \\ \vdots \\ \theta_n \end{bmatrix} - \begin{bmatrix} y^{(1)} \\ y^{(2)} \\ \vdots \\ y^{(m)} \end{bmatrix} \right)$$

Si se definen las siguientes cantidades matriciales:

$$\Theta = \begin{bmatrix} \theta_0 \\ \theta_1 \\ \vdots \\ \theta_n \end{bmatrix} \quad \tilde{X} = \begin{bmatrix} 1 & 1 & \cdots & 1 \\ x_1^{(1)} & x_1^{(2)} & \cdots & x_1^{(m)} \\ \vdots & \vdots & \cdots & \vdots \\ x_n^{(1)} & x_n^{(2)} & \cdots & x_n^{(m)} \end{bmatrix} \quad y = \begin{bmatrix} y^{(1)} \\ y^{(2)} \\ \vdots \\ y^{(m)} \end{bmatrix} \quad (1)$$

La función de coste se expresa así:

$$J(\Theta) = \frac{1}{2m} (\Theta^T \tilde{X} - y^T)(\Theta^T \tilde{X} - y^T)^T$$

Aplicando la transpuesta y expandiendo los productos:

$$\begin{aligned} J(\Theta) &= \frac{1}{2m} (\Theta^T \tilde{X} - y^T)([\Theta^T \tilde{X}]^T - y) \\ &= \frac{1}{2m} (\Theta^T \tilde{X} - y^T)(\tilde{X}^T \Theta - y) \\ &= \frac{1}{2m} (\Theta^T \tilde{X} \tilde{X}^T \Theta - \Theta^T \tilde{X} y - y^T \tilde{X}^T \Theta + y^T y) \end{aligned}$$

Con esta expresión podemos calcular el gradiente de J :

$$\nabla_{\Theta} J = \frac{1}{2m} \nabla_{\Theta} (\Theta^T \tilde{X} \tilde{X}^T \Theta - \Theta^T \tilde{X} y - y^T \tilde{X}^T \Theta + y^T y)$$

El último término no contribuye al gradiente pues es un producto de vectores constantes, además el segundo y tercer término son iguales: $\tilde{X}^T \Theta$ es un vector de dimensiones $(m \times n)(n \times 1) = (m \times 1)$ y y^T es un vector de $(1 \times m)$ de modo que $y^T \tilde{X}^T \Theta$ es de dimensiones $(1 \times m)(m \times 1) = (1 \times 1)$, al ser un escalar este es igual a su transpuesta, por lo que $y^T \tilde{X}^T \Theta = (y^T \tilde{X}^T \Theta)^T = \Theta^T \tilde{X} y$.

$$\nabla_{\Theta} J = \frac{1}{2m} \nabla_{\Theta} (\Theta^T \tilde{X} \tilde{X}^T \Theta - 2\Theta^T \tilde{X} y) \quad (2)$$

Para efectuar la derivada traemos dos resultados importantes, para una matriz simétrica A y un vector \mathbf{b} :

$$\begin{aligned} \nabla_{\mathbf{x}} (\mathbf{x}^T A \mathbf{x}) &= 2A\mathbf{x} \\ \nabla_{\mathbf{x}} (\mathbf{b}^T \mathbf{x}) &= \nabla_{\mathbf{x}} (\mathbf{x}^T \mathbf{b}) = \mathbf{b} \end{aligned} \quad (3)$$

Al notar que $S = \tilde{X} \tilde{X}^T = (\tilde{X} \tilde{X}^T)^T = \tilde{X} \tilde{X}^T = S^T$, y haciendo uso de la ecuación (3) en la expresión (2):

$$\begin{aligned} \nabla_{\Theta} J &= \frac{1}{2m} \nabla_{\Theta} (\Theta^T \tilde{X} \tilde{X}^T \Theta - 2\Theta^T \tilde{X} y) \\ &= \frac{1}{2m} [\nabla_{\Theta} (\Theta^T S \Theta) - 2\nabla_{\Theta} (\Theta^T \tilde{X} y)] \\ &= \frac{1}{2m} [2S\Theta - 2\tilde{X} y] \\ &= \frac{1}{m} [\tilde{X} \tilde{X}^T \Theta - \tilde{X} y] \end{aligned}$$

El mínimo de J se obtiene igualando a cero el gradiente.

$$\begin{aligned} \nabla_{\Theta} J = 0 &\longrightarrow \frac{1}{m} [\tilde{X} \tilde{X}^T \Theta - \tilde{X} y] = 0 \\ \tilde{X} \tilde{X}^T \Theta - \tilde{X} y &= 0 \\ \Theta &= (\tilde{X} \tilde{X}^T)^{-1} \tilde{X} y \end{aligned} \quad (4)$$