

# UdeA

## **Detección de Ondas Gravitacionales Utilizando una Red Neuronal Convolutiva**

**Entrenamiento y Analisis de la Red.**

**Juan Diego Garro Cataño**

**Emmanuel Sanchez Vasquez**

Instituto de Física  
Facultad de Ciencias Exactas y Naturales  
Universidad de Antioquia UdeA

29 de noviembre de 2023

- 1. Manejo de los datos.**
- 2. Arquitectura de la red.**
- 3. Entrenamiento de la red neuronal.**
- 4. Metricas.**

Para nuestro proyecto trabajamos con un dataset proporcionado por la plataforma de Kaggle, en el cual había datos con extensión (.npy), cada archivo contiene tres series de tiempo de los detectores Ligo Hanford, Ligo Livingstone y Virgo cada serie con una duración de 2 segundos y un muestreo de 2.048 Hz




Figura: Datos de Ondas Gravitacionales y Ruido de los detectores.

Para el análisis de los datos se realiza una transformada de Fourier en escala logarítmica, para analizar las ondas en el espacio de las frecuencias, esto nos arroja un espectrograma bidimensional, que será el input de la red neuronal convolucional.




Figura: Espectrograma de los datos de los detectores.

Se realiza un batch de los datos para equilibrar la eficiencia computacional y la precisión del modelo durante el entrenamiento de la red neuronal, para nuestro caso el tamaño del batch es de 256




Figura: Arquitectura de la red neuronal convolucional.

Utilizando 3.3 GB en los datos de entrenamiento, tenemos los siguientes valores para la función de pérdida y el valor auc (Area Under Curve) el cual nos da cuenta de la capacidad del modelo para realizar predicciones.

```
Epoch 1/10
131/131 [=====] - 10885s 83s/step - loss: 0.6154 - auc: 0.7029 - val_loss: 0.5352 - val_auc: 0.7969
Epoch 2/10
131/131 [=====] - 325s 2s/step - loss: 0.5151 - auc: 0.8070 - val_loss: 0.5511 - val_auc: 0.8099
Epoch 3/10
131/131 [=====] - 310s 2s/step - loss: 0.5028 - auc: 0.8150 - val_loss: 0.5319 - val_auc: 0.8221
Epoch 4/10
131/131 [=====] - 317s 2s/step - loss: 0.4902 - auc: 0.8248 - val_loss: 0.5042 - val_auc: 0.8223
Epoch 5/10
131/131 [=====] - 311s 2s/step - loss: 0.4810 - auc: 0.8319 - val_loss: 0.4934 - val_auc: 0.8289
Epoch 6/10
131/131 [=====] - 312s 2s/step - loss: 0.4741 - auc: 0.8372 - val_loss: 0.4897 - val_auc: 0.8257
Epoch 7/10
131/131 [=====] - 315s 2s/step - loss: 0.4672 - auc: 0.8424 - val_loss: 0.4857 - val_auc: 0.8309
Epoch 8/10
131/131 [=====] - 321s 2s/step - loss: 0.4647 - auc: 0.8440 - val_loss: 0.4962 - val_auc: 0.8193
Epoch 9/10
131/131 [=====] - 313s 2s/step - loss: 0.4509 - auc: 0.8545 - val_loss: 0.4877 - val_auc: 0.8303
Epoch 10/10
131/131 [=====] - 329s 3s/step - loss: 0.4463 - auc: 0.8580 - val_loss: 0.4920 - val_auc: 0.8263
<keras.src.callbacks.History at 0x7a030deaad70>
```

Figura: Entrenamiento de la CNN con 3.3GB.

```
1/1 [=====] - 2s 2s/step - loss: 0.5532 - auc_2: 0.7981
Pérdida en datos de prueba: 0.5532
AUC en datos de prueba: 0.7981
1/1 [=====] - 2s 2s/step
```

Figura: Auc para pocos datos.

```
Epoch 1/10
1/1 [=====] - 0s 0s/step - loss: 0.6940 - auc_2: 0.5179 - val_loss: 0.6873 - val_auc_2: 0.6885
Epoch 2/10
1/1 [=====] - 0s 0s/step - loss: 0.6893 - auc_2: 0.5558 - val_loss: 0.6885 - val_auc_2: 0.6925
Epoch 3/10
1/1 [=====] - 0s 0s/step - loss: 0.6883 - auc_2: 0.5835 - val_loss: 0.6714 - val_auc_2: 0.7087
Epoch 4/10
1/1 [=====] - 0s 0s/step - loss: 0.6799 - auc_2: 0.6338 - val_loss: 0.6498 - val_auc_2: 0.7259
Epoch 5/10
1/1 [=====] - 0s 0s/step - loss: 0.6440 - auc_2: 0.6749 - val_loss: 0.6298 - val_auc_2: 0.7639
Epoch 6/10
1/1 [=====] - 0s 0s/step - loss: 0.6321 - auc_2: 0.7049 - val_loss: 0.6743 - val_auc_2: 0.7872
Epoch 7/10
1/1 [=====] - 0s 0s/step - loss: 0.5940 - auc_2: 0.7128 - val_loss: 0.6575 - val_auc_2: 0.8046
Epoch 8/10
1/1 [=====] - 0s 0s/step - loss: 0.5618 - auc_2: 0.7679 - val_loss: 0.6428 - val_auc_2: 0.7947
Epoch 9/10
1/1 [=====] - 0s 0s/step - loss: 0.5346 - auc_2: 0.7919 - val_loss: 0.5941 - val_auc_2: 0.8194
Epoch 10/10
1/1 [=====] - 0s 0s/step - loss: 0.5340 - auc_2: 0.7918 - val_loss: 0.5932 - val_auc_2: 0.7901
clear_vcc_callbacks-history at 0x7a1a1a1a1a1a
```

Figura: Confusion Matriz.






Figura: Grafica ROC.




Figura: Confusion Matriz.



R. Qiu, P. G. Krastev, K. Gill y E. Berger, "Deep learning detection and classification of gravitational waves from neutron star-black hole mergers", Phys. Lett. B 2023, 137850. <https://doi.org/10.1016/j.physletb.2023.137850>



"G2Net Gravitational Wave Detection | Kaggle"(s. f.).  
<https://www.kaggle.com/competitions/g2net-gravitational-wave-detection/code>

# Gracias